Automatische Pilzerkennung mittels Deep Learning

iisy
intelligent
interactive
systems group

Lukas Reckwald et al.[1]

[1]Berliner Hochschule für Technik (BHT)

Maschinelles Sehen
SoSe 2026
Prof. Dr. Hildebrand

Problem

Essbare und giftige Pilzarten sehen sich oft täuschend ähnlich. Eine Fehlbestimmung kann gesundheitsgefährlich sein.

Ziel: ein Bildklassifikationsmodell, das aus einem Foto sowohl die Art als auch eine essbar/giftig-Einschätzung liefert.



Cantharellus cibarius - essbar



Hygrophoropsis aurantiaca - giftig

Pfifferling (*links*) vs "falscher Pfifferling" (*rechts*)

Related Work / Motivation

- Datensatz *"Mushroom Species Recognition*" (Kaggle, zlatan599): 169 Pilzarten, 104.088 Bilder
- Standardansatz in der Bildklassifikation: CNNs + Transfer Learning von ImageNet-vortrainierten Netzen
- Motivation: praktischer Nutzen für Pilzsammler, gleichzeitig gute Aufgabe zum Erproben moderner Deep-Learning-Methoden (deswegen auch das Modul)

Your Approach / Solution

- Transfer Learning mit zwei vortrainierten CNN-Backbones: ResNet50 und MobileNetV2
- Eine Vorhersage, zwei Ebenen: Art-Klassifikation + daraus abgeleitete essbar/giftig-Klassifikation
- Klassenungewichteter Loss statt Sampler, um seltene Arten nicht zu vernachlässigen
- Direkter Architekturvergleich

References

[1] zlatan599. *Mushroom Species Recognition Dataset.* Kaggle, 2024.

[2] He et al. *Deep Residual Learning for Image Recognition.* CVPR 2016.

[3] Sandler et al. *MobileNetV2: Inverted Residuals and Linear Bottlenecks.* CVPR 2018.

Method / Pipeline / Algorithm / Process

1 Rohdaten
Kaggle-Datensatz, 169 Pilzarten, ca. 104.000 Fotos

↓

2 Aufbereitung
essbar/giftig je Art zugeordnet, doppelte Bilder entfernt

↓

3 Split
72.858 Train / 15.616 Val / 15.614 Test

↓

4 Augmentierung
nur Training: Spiegeln, Rotation +/- 20 Grad, Helligkeit/Kontrast/Farbe, 224×224 Bildauflösung

↓

5 Modell
vortrainiertes CNN (ImageNet), neuer Kopf für 169 Arten: ResNet50 & MobileNetV2

↓

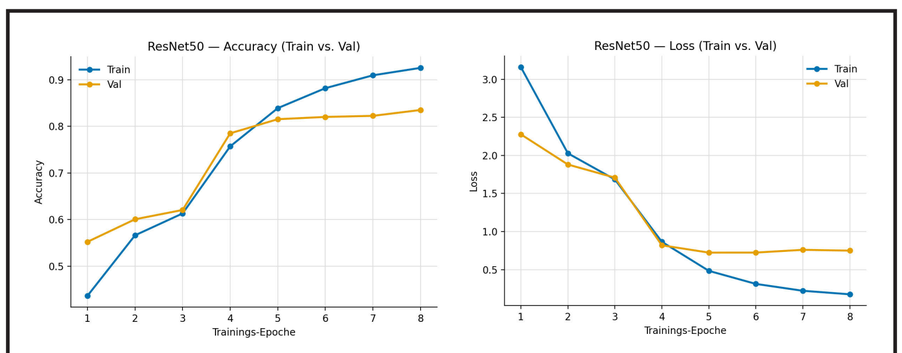
6 Zweiphasiges Training

Phase 1 (Epoche 1-3)	→	Phase 2 (Epoche 4-8)
nur der neue Kopf wird trainiert, Rest eingefroren		ganzes Netz fein angepasst, 10x langsamer

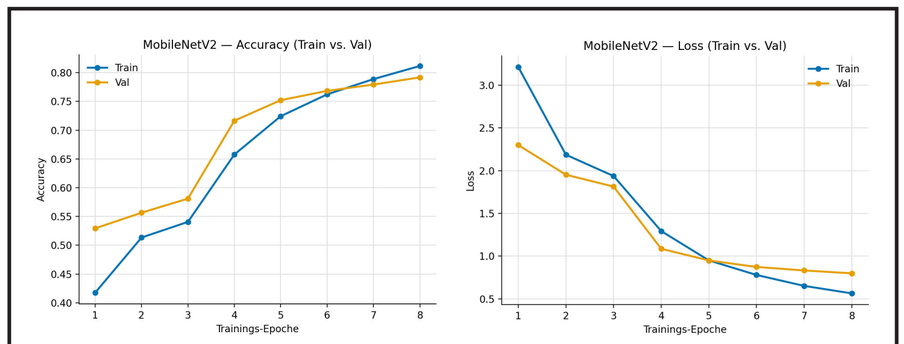
Loss gewichtet seltene Arten stärker · Training auf Google Colab (Cloud-GPU)

↓

7 Essbar/giftig-Ableitung
kein eigenes Training. Aus der Art-Vorhersage über feste Zuordnungstabelle abgeleitet



ResNet50

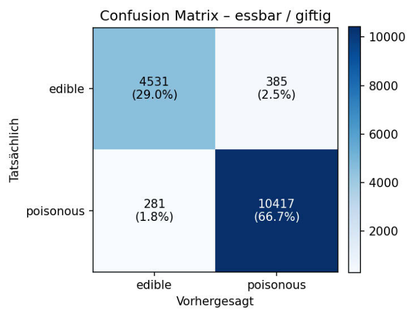


MobileNetV2

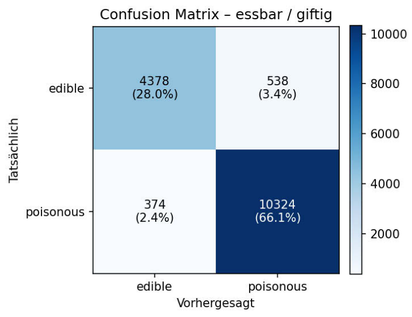
Results

Modell	Accuracy essbar/giftig	Accuracy Art (169 Kl.)	Macro-F1 Art
ResNet50	95,7 %	83,5 %	79,3 %
MobileNetV2	94,2 %	78,5 %	73,9 %

- ResNet50 schlägt MobileNetV2 in beiden Aufgaben durchgehend
- MobileNetV2 war nach 8 Epochen noch nicht auskonvergiert
- ResNet50 zeigt größere Lücken zwischen Trainings- und Validierungsgenauigkeit
- Verwechslungen zwischen Arten bleiben fast immer innerhalb der selben essbar/giftig-Gruppe (sicherheitsrelevante Fehler sind selten)



ResNet50



MobileNetV2

Domain-Shift-Test

Modell	Gattung Top-1	Gattung Top-5	essbar/ giftig
ResNet50	15,0 %	20,0 %	55,0 %
MobileNetV2	10,0 %	30,0 %	60,0 %

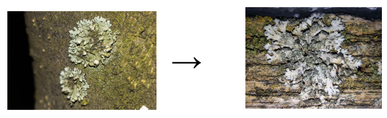
Out-Of-Domain-Test

Modell	Top-1-Accuracy	Top-5-Accuracy	essbar/ giftig-Accuracy
ResNet50	60,0 %	100,0 %	100,0 %
MobileNetV2	65,0 %	95,0 %	100,0 %

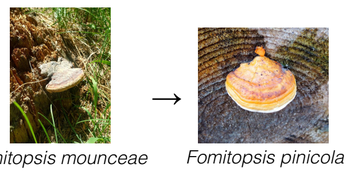
Typische Verwechselungen



Leccinum versipelle → *Leccinum aurantiacum*



Physcia adscendens → *Phaeophyscia orbicularis*



Fomitopsis mounceae → *Fomitopsis pinicola*

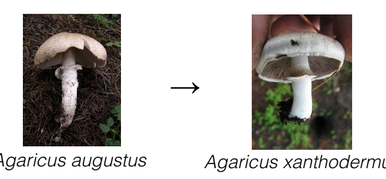
Grenzüberschreitende Verwechselungen



Coprinopsis atramentaria → *Coprinellus micaceus*



Agaricus xanthodermus → *Volvopluteus gloiocephalus*



Agaricus augustus → *Agaricus xanthodermus*